

MiniProyecto.Grupo-L

Alejandro Adán, Edu Carbó, Noé Cubero, Víctor Ínigo Y Anastasia Gheorghiu

2026-04-13

Contents

1	Introducción	2
2	Empezamos a trabajar con los datos	2
3	Preguntas de Investigación	3
3.1	De todas las herramientas disponibles en el Aula Virtual (foros, archivos, cuestionarios), ¿cuáles son las que registran un mayor volumen de interacciones?	4
3.2	¿En qué franjas horarias se concentra la mayor parte de nuestra actividad? ¿Predomina el trabajo vespertino o el nocturno?	5
3.3	Desigualdad en la participación: ¿Quién usa más el Aula Virtual?	5
3.4	¿Cómo entra la clase al Aula Virtual? ¿Usamos todos el ordenador o hay gente que usa la aplicación del móvil?	6
4	Analizamos actitudes de los estudiantes	7
4.1	¿Qué días de la semana concentran más actividad en el Aula Virtual?	7
4.2	¿Cuáles son los eventos específicos más frecuentes dentro de la plataforma?	8
4.3	¿Qué fechas concretas registran más interacciones?	8
4.4	¿Qué usuarios acceden al Aula Virtual durante más días diferentes?	9
4.5	¿Cuántas direcciones IP diferentes utiliza cada usuario?	10
5	Relaciones que podemos investigar	10
5.1	Tareas entregadas frente a racha de días seguidos	10
5.2	Atención a los alumnos	11
6	Hábitos y Conductas: Lo que los Logs Dicen de Nosotros	13
6.1	¿Existe el “Efecto Maratón”?	13
6.2	“Usuarios Fantasma”: ¿Qué porcentaje de la actividad corresponde a una consulta pasiva frente a una participación activa?	14
6.3	El “Pánico del Deadline”: ¿Se incrementa la velocidad y frecuencia de las acciones de los usuarios en situaciones de posible presión temporal?	15

6.4	El “Rastro del Estudiante”: ¿Cuál es la secuencia de acciones más frecuente que precede al envío de una tarea?	16
6.5	Minería de “S.O.S”: ¿Qué eventos técnicos o errores de sistema predominan en los registros de los estudiantes?	17

1 Introducción

El conjunto de datos utilizado para este análisis proviene de los registros de actividad (logs) del Aula Virtual del grado de Ciencia de Datos. Estos datos han sido previamente anonimizados para garantizar la privacidad de los usuarios mientras se mantiene la integridad de la información académica y de interacción necesaria para el estudio.

2 Empezamos a trabajar con los datos

Para empezar a sacar conclusiones de los logs que tenemos, hace falta entender todos los datos que nos han sido dados. Esto se llama hacer un análisis exploratorio de los datos(EDA). En este paso de la investigación, se comprueba con qué tipo de datos vamos a trabajar e intentamos obtener una idea general de cómo estos están organizados para luego poder manipularlos a la hora de hacernos preguntas y poder responderlas.

2.0.1 Cargar todas las librerías

Para empezar, cargamos todas las librerías que utilizaremos en el EDA. En este caso, cargaremos: knitr, tidyverse, dplyr, tidyr, readr, ggplot2, lubridate.

2.0.2 Importamos el dataset

Necesitaremos cargar los datos que se encuentran en la carpeta data. Con la función “read_csv” lo haremos fácilmente. Esta función crea un data frame con los datos del csv.

Teniendo ya los datos cargados, observamos de qué tipo es cada variable y las características clave de cada una.

```
##      Hora      Nombre completo del usuario Usuario afectado
## Length:109746 Length:109746      Length:109746
## Class :character Class :character      Class :character
## Mode :character Mode :character      Mode :character
## Contexto del evento Componente      Nombre evento      Descripción
## Length:109746 Length:109746      Length:109746      Length:109746
## Class :character Class :character      Class :character      Class :character
## Mode :character Mode :character      Mode :character      Mode :character
## Origen      Dirección IP
## Length:109746 Length:109746
## Class :character Class :character
## Mode :character Mode :character
```

El dataset contiene 109746 observaciones y 9 variables, cuyos nombres son: Hora, Nombre completo del usuario, Usuario afectado, Contexto del evento, Componente, Nombre evento, Descripción, Origen, Dirección IP.

Table 1: Estructura inicial de los logs de la asignatura

Hora	Nombre completo del usuario	Usuario afectado	Contexto del evento
3/03/26, 10:59:04	U0072	NA	Curso: 2024-25 Tractament de les dades Gr.A-T (3/03/26, 10:59:04)
3/03/26, 10:58:57	U0072	NA	Curso: 2024-25 Tractament de les dades Gr.A-T (3/03/26, 10:58:57)
3/03/26, 10:58:30	U0072	NA	Curso: 2024-25 Tractament de les dades Gr.A-T (3/03/26, 10:58:30)
3/03/26, 10:57:28	U0072	NA	Curso: 2024-25 Tractament de les dades Gr.A-T (3/03/26, 10:57:28)
3/03/26, 10:57:09	U0072	NA	Curso: 2024-25 Tractament de les dades Gr.A-T (3/03/26, 10:57:09)

Vamos a ver cómo están los datos organizados inicialmente. Para ello mostramos las 5 primeras filas del dataframe creado a partir de los datos

1 De momento todas las variables son de tipo carácter. Esto lo tenemos que modificar dependiendo de la información que tiene cada una.

2.0.3 Operaciones con las diferentes variables

Empezamos con la variable hora. Hay que cambiarla a formato fecha-hora. Para ello usamos la función “dmy_hms”, que cambia a día-mes-año - hora-minuto-segundo.

Al transformarlo a posix lt y hacer el summary, vemos que la fecha en la que se hizo el primer log es en 2024 y el último en marzo de este año.

También hay que saber cuántos valores nulos hay en el dataframe

```
##              Hora Nombre completo del usuario
##              0              0
##      Usuario afectado      Contexto del evento
##              69346              0
##              Componente      Nombre evento
##              0              0
##      Descripción              Origen
##              0              0
##      Dirección IP
##              2857
```

Como se observa en el análisis de valores nulos, la variable **Usuario afectado** presenta 48.203 NAs. Esto no se debe a un error en la carga de datos, sino a la naturaleza de los logs: la mayoría de las interacciones en el Aula Virtual son individuales. Según las especificaciones del proyecto, esta variable solo registra información cuando una acción afecta a terceros, por lo que mantendremos estos registros para el análisis. El resto de variables no presentan valores nulos, lo que indica que el dataset es robusto para el estudio. Ahora ya pasamos a las preguntas.

3 Preguntas de Investigación

Tras una primera revisión de los objetivos del proyecto y de la estructura de los logs, nuestro grupo ha definido varias preguntas:

3.1 De todas las herramientas disponibles en el Aula Virtual (foros, archivos, cuestionarios), ¿cuáles son las que registran un mayor volumen de interacciones?




Figure 1: Componentes más utilizados

Al mirar el gráfico 1, queda claro que usamos el Aula Virtual sobre todo para dos cosas: descargar apuntes (Archivos) y subir trabajos (Tareas). Las herramientas para hablar con otros o trabajar en grupo, como los Foros o las Wikis, se usan muchísimo menos. En resumen: vamos a la plataforma a por el material y a entregar lo que nos piden, no a socializar.

3.2 ¿En qué franjas horarias se concentra la mayor parte de nuestra actividad? ¿Predomina el trabajo vespertino o el nocturno?




Figure 2: Franjas Horarias

El perfil mayoritario del estudiante de esta asignatura es de carácter vespertino, concentrando su esfuerzo principal en las horas posteriores a la docencia presencial y reduciendo su actividad durante la noche como es visto en 2.

3.3 Desigualdad en la participación: ¿Quién usa más el Aula Virtual?

Para responder a la pregunta de si el uso de la plataforma es equitativo o si hay “power users” (usuarios muy intensivos), hemos analizado la cantidad de interacciones por cada estudiante.




Figure 3: Usos Aula Virtual

3 muestra que el uso no es igualitario. Hay 2 o 3 personas (seguramente el profesor o alumnos muy intensos) que acumulan casi toda la actividad de la plataforma, mientras que el resto de la clase hace un uso mucho más normal y puntual.

3.4 ¿Cómo entra la clase al Aula Virtual? ¿Usamos todos el ordenador o hay gente que usa la aplicación del móvil?

Otra pregunta interesante para entender nuestros hábitos es conocer qué plataformas utilizamos para acceder al Aula Virtual. ¿Es el ordenador la única vía o utilizamos dispositivos móviles? Analizamos la variable `Origen`.




Figure 4: Vías de acceso AV

Además de los accesos habituales, los datos registran una cantidad residual de eventos con origen ‘cli’ y ‘restore’. Estos no corresponden a interacciones reales de los estudiantes, sino a tareas de mantenimiento automático del servidor de Moodle y a la restauración de la copia de seguridad de la asignatura a principios de curso por parte del profesorado 4.

4 Analizamos actitudes de los estudiantes

En esta parte del trabajo se analiza la actividad del Aula Virtual desde una perspectiva temporal y de comportamiento. El objetivo es complementar los análisis anteriores, que ya estudian los recursos más usados, las franjas horarias, los usuarios más activos y las vías de acceso.

4.1 ¿Qué días de la semana concentran más actividad en el Aula Virtual?

Para responder a esta pregunta se transforma la variable **Hora** en una variable temporal y se extrae el día de la semana. Después se cuentan todos los eventos registrados para cada día.




Figure 5: Días de la semana

El gráfico 5 permite observar si la actividad se concentra principalmente durante los días lectivos o si también existe uso relevante durante el fin de semana. Esto ayuda a entender si el Aula Virtual se utiliza solamente como apoyo a las clases o también como herramienta de trabajo autónomo fuera del horario habitual.

4.2 ¿Cuáles son los eventos específicos más frecuentes dentro de la plataforma?

En esta pregunta se analiza la variable **Nombre evento**, que recoge la acción concreta realizada dentro del Aula Virtual. Se cuentan los eventos y se muestran los diez más frecuentes.

Este análisis 2 es más detallado que estudiar únicamente los componentes, porque permite diferenciar acciones concretas como visualizar recursos, consultar contenidos, entregar tareas o acceder a diferentes elementos de Moodle. Así se puede interpretar mejor qué tipo de interacción predomina en la plataforma.

4.3 ¿Qué fechas concretas registran más interacciones?

Para detectar picos de actividad, se agrupan los eventos por fecha y se seleccionan los diez días con mayor número de interacciones.

Table 2: Top 10 eventos más frecuentes en el Aula Virtual

Nombre evento	Frecuencia
Módulo de curso visto	23535
Curso visto	20430
Usuario calificado	12846
Se ha visualizado el estado de la entrega.	9388
Intento de cuestionario visualizado	3877
Intento de cuestionario actualizado	3676
Pregunta creada	3395
Informe de notas de usuario visto	2771
Informe de sesión visto	2680
Intento de cuestionario guardado automáticamente	2618




Figure 6: Fechas con más interacciones

Las fechas con mayor actividad, como vemos en 6, pueden estar relacionadas con entregas, preparación de exámenes, publicación de materiales o momentos importantes de la asignatura.

4.4 ¿Qué usuarios acceden al Aula Virtual durante más días diferentes?

En este caso no se analiza solo el número total de clics, sino la continuidad temporal de cada usuario. Para ello se calcula cuántos días distintos aparece cada usuario en los registros.

Table 3: Usuarios con mayor número de días activos

Nombre completo del usuario	Dias_activos	Total_eventos
U0084	155	2053
U0104	124	1622
U0006	109	2623
U0069	108	2196
U0058	105	1838
U0072	105	13079
U0073	101	1531
U0123	101	1728
U0087	98	1347
U0110	96	1027

Table 4: Usuarios con mayor número de direcciones IP diferentes

Nombre completo del usuario	IPs_diferentes	Total_eventos
U0001	1249	6932
U0006	153	2623
U0026	128	1286
U0102	123	1239
U0044	121	1301
U0041	113	1374
U0058	113	1838
U0003	112	1077
U0079	105	1165
U0015	103	862

Este resultado 3 permite distinguir entre usuarios que acceden de forma puntual y usuarios que utilizan el Aula Virtual de manera más continua a lo largo del curso. Un usuario puede tener muchos clics en pocos días, mientras que otro puede tener una actividad más repartida en el tiempo.

4.5 ¿Cuántas direcciones IP diferentes utiliza cada usuario?

Por último, se analiza la diversidad de conexión de cada usuario contando el número de direcciones IP distintas asociadas a sus eventos.

El número de direcciones IP diferentes 4 sirve como aproximación a la variedad de conexiones utilizadas. No permite identificar dispositivos concretos ni lugares exactos, pero puede indicar si algunos usuarios acceden desde varias redes, como la universidad, casa u otros espacios.

Además, los valores muy altos de direcciones IP diferentes deben interpretarse con cautela, ya que pueden corresponder a usuarios con un uso muy intensivo de la plataforma, conexiones desde muchas redes distintas o perfiles con un papel especial dentro del curso.

5 Relaciones que podemos investigar

5.1 Tareas entregadas frente a racha de días seguidos

Otra cosa que hemos querido investigar es si los estudiantes que se conectan muchos días seguidos terminan entregando más tareas. Para eso, calculamos para cada usuario la racha más larga de días consecutivos que

tuvo actividad (solo con accesos desde el ordenador, que son los normales) y lo comparamos con el número de entregas que hizo. Al final miramos la correlación para ver si hay relación entre ser constante y entregar más trabajos.

¿Conectarse más días seguidos lleva a entregar más tareas?

Cada punto es un estudiante. La línea muestra la tendencia lineal




Figure 7: Entregas por días seguidos

La correlación de 0.33 en 7 nos indica que tener una racha alta de actividad, NO significa entregar más tareas. Es cierto que la correlación es positiva, pero es demasiado baja como para poder sacar una conclusión que se pueda defender.

5.2 Atención a los alumnos

Dejando de centrarnos específicamente en los alumnos, hemos decidido centrarnos en si se presta atención a todos los alumnos por igual o si hay algunos que reciben mucho más feedback que otros. Para responder, contamos cuántas veces aparece cada estudiante en la columna Usuario afectado (eso indica que alguien hizo algo que le afectaba, como corregirle o mirar su perfil). Luego hicimos un gráfico con todos los alumnos ordenados de los que más atención reciben a los que menos, para ver si la atención se reparte de forma pareja o si unos pocos acumulan casi todo.

¿Reciben todos los alumnos la misma atención?

Total de alumnos que reciben atención: 123




Figure 8: Distribución de la atención docente: eventos que afectan a cada alumno

Viendo el gráfico resultante 8, podemos ver que hay una gran cantidad de alumnos que no han tenido ninguna o casi ninguna atención, lo que resalta con los otros muchos que sí que han tenido muchas retroalimentaciones y “visitas” de su perfil.

Vamos a hacer una comparación para ver si los alumnos que más entregas han hecho son los que más atención han recibido.




Figure 9: Relación entre atención recibida y tareas entregadas por alumno

Como era de esperar, al comparar estos dos parámetros, vemos que los alumnos que más tareas han entregado (de normal), son los que más retroalimentaciones se han llevado. Al tener la correlación positiva y casi llegando a 0.7, es un valor que sí que es para tener en cuenta y nos da la información de que están relacionadas.

6 Hábitos y Conductas: Lo que los Logs Dicen de Nosotros

6.1 ¿Existe el “Efecto Maratón”?

Analizamos cuánto tiempo pasa desde el primer clic hasta el último en un mismo día.



Figure 10: Efecto maratón

Mediante el diagrama de cajas 10 revela que, aunque la gran mayoría de los estudiantes realizan consultas rápidas y puntuales (reflejado en una mediana cercana a cero), existe una asimetría positiva muy marcada con la presencia de outliers significativos. Estos valores atípicos, que alcanzan jornadas de hasta 15 o 20 horas, representan comportamientos de estudio intensivo o posibles descuidos técnicos al dejar la sesión abierta, lo que demuestra una variabilidad extrema en el esfuerzo dedicado.

6.2 “Usuarios Fantasma”: ¿Qué porcentaje de la actividad corresponde a una consulta pasiva frente a una participación activa?

Dividimos a la clase según si solo miran o si realmente envían cosas.




Figure 11: Usuarios fantasma

Esta desproporción¹¹ indica que el comportamiento principal de los estudiantes se centra en el consumo de contenidos (visualización de materiales, descarga de archivos y lectura de enunciados) en lugar de la generación de contenido o participación directa.

6.3 El “Pánico del Deadline”: ¿Se incrementa la velocidad y frecuencia de las acciones de los usuarios en situaciones de posible presión temporal?

Calculamos la frecuencia de clics. Si hay muchos clics seguidos (pocos segundos entre ellos), hay estrés.

Gráfico de 'Pánico': Rapidez de clics




Figure 12: Pánico del Deadline

El gráfico de densidad del tiempo entre clics 12 muestra un pico extremadamente pronunciado en el intervalo de 0 a 10 segundos, lo que revela un comportamiento de navegación frenética y de alta intensidad. Esta acumulación masiva en tiempos tan cortos sugiere que, cuando los usuarios están activos, no se limitan a leer de forma estática, sino que interactúan con la plataforma de manera muy rápida (descargando múltiples archivos, saltando entre secciones o refrescando páginas).

La rápida caída de la curva hacia los 60 segundos confirma que las sesiones de trabajo en el Aula Virtual se caracterizan por ráfagas de actividad muy concentradas, lo que podría interpretarse como el “Pánico del Deadline” o momentos de alta presión donde el estudiante busca y procesa información a gran velocidad para cumplir con una tarea.

6.4 El “Rastro del Estudiante”: ¿Cuál es la secuencia de acciones más frecuente que precede al envío de una tarea?

¿Qué recurso abrieron justo el segundo antes de darle a “Enviar”?

Table 5: Principales problemas técnicos detectados

Evento de Error	Frecuencia
Elemento de calificación actualizado	1
Elemento de calificación creado	1
Elemento de calificación eliminado	1




Figure 13: Rastro del estudiante

El gráfico 13 muestra que la acción que precede con más frecuencia al “Envío de una entrega” es, curiosamente, el propio evento de “Se ha enviado una entrega”. Esto indica un comportamiento de revisión o duplicidad: los alumnos comprueban inmediatamente el estado de su envío o realizan varios intentos seguidos para asegurarse de que el archivo es correcto.

El resto de acciones del ranking, como “Módulo de curso visto”, confirman que el paso previo lógico es la navegación por la estructura del curso para localizar el buzón de entrega.

6.5 Minería de “S.O.S”: ¿Qué eventos técnicos o errores de sistema predominan en los registros de los estudiantes?

Buscamos palabras de error en las descripciones de los logs.

Al investigar los posibles fallos en el Aula Virtual 5, hemos descubierto que el sistema es sumamente estable. Prácticamente no existen errores técnicos reales; de hecho, los pocos casos que aparecen con un valor de ‘1’

en la tabla son situaciones aisladas o simplemente tareas que llevan la palabra ‘problema’ en su título. Esto nos indica que los estudiantes no dejan de entrar por fallos de la web, sino por otros motivos, ya que la plataforma funciona sin problemas técnicos recurrentes.